

Relatório Final

Estudo de Clustering sobre Procura de Reservas Hoteleiras

Equipa: G8-P2 – Rodrigo Caeiro (75512), Gustav Barreira (75616)

Número do grupo: 8

Aprendizagem Não Supervisionada - 2025/2026

Tag do repositório: `Final Submission`

Execução de referência: `run_id = 20260604T100721Z`

Data: 04/06/2026

Resumo

Este relatório documenta um estudo reprodutível de segmentação não supervisionada sobre registos de reservas hoteleiras, utilizando o dataset *course release v1*. A questão de investigação é: que perfis de reserva emergem naturalmente a partir de variáveis disponíveis no momento da reserva, sem usar categorias conhecidas como o estado de cancelamento. Implementámos uma pipeline de point-to-point com verificação da qualidade dos dados, pré-processamento sensível a leakage, codificação de dados mistos e comparação de modelos entre K-Means, iK-Means e clustering hierárquico de Ward. A avaliação combina três índices internos (Silhouette, Calinski–Harabasz, Davies–Bouldin), governação do tamanho mínimo dos clusters e testes de estabilidade com dez seeds. A solução selecionada é K-Means com $k=4$ na representação Std-SemADR ($n=117\,429$, $d=52$), com Silhouette 0,1256, Davies–Bouldin 2,0977 e cluster mínimo com 2,93% das observações. A interpretação dos clusters revela um bloco dominante de reservas online/OTA e um segmento corporativo pequeno, mas distinto, com *lead time* muito inferior. Análises de sensibilidade sustentam a narrativa qualitativa, evidenciando a instabilidade moderada da partição medida por ARI. A principal limitação é a ausência de categorias conhecidas e as restrições geométricas da distância euclidiana em espaços *one-hot* de baixa densidade.

Palavras-chave: procura de reservas hoteleiras; clustering; segmentação; dados mistos; reprodutibilidade; silhueta; estabilidade de clusters.

1. Introdução

Os padrões de reserva observados na indústria hoteleira apresentam uma elevada heterogeneidade. Fatores como o canal de reserva utilizado, a antecedência da marcação (*lead time*), a duração da estadia e o perfil do cliente variam substancialmente entre reservas. No entanto, os sistemas transacionais utilizados pelas organizações raramente disponibilizam categorias pré-definidas que permitam segmentar estes comportamentos de forma direta. Neste contexto, o presente projeto aborda uma questão central de aprendizagem não supervisionada: que perfis de reserva relevantes podem ser identificados a partir das variáveis disponíveis no momento da reserva?

O clustering constitui uma abordagem adequada para este problema, uma vez que, permite modelar explicitamente relações de semelhança entre observações num espaço de representação cuidadosamente definido. A partir dessa representação, é possível identificar agrupamentos naturais e avaliar a sua qualidade

recorrendo a métricas de validade interna e análises de robustez. Esta abordagem torna-se assim, particularmente relevante quando os dados não incluem categorias conhecidas que permitam recorrer a métodos supervisionados.

A contribuição deste relatório assenta em quatro dimensões principais. Em primeiro lugar, é proposta uma pipeline reproduzível, suportada por mecanismos de rastreabilidade dos dados e registo sistemático das experiências realizadas. Em segundo lugar, são comparadas diferentes famílias de algoritmos de clustering incluindo métodos centroidais e hierárquicos. Em terceiro lugar, é adotado um processo de seleção de modelos que combina métricas de qualidade com restrições explícitas de governação. E por último, foi desenvolvida uma interpretação dos clusters obtidos com base em perfis comportamentais potencialmente relevantes para a tomada de decisão.

A motivação prática deste estudo prende-se na necessidade de identificar padrões de comportamento dos clientes antes da ocorrência de eventos futuros, como o check-in ou o cancelamento da reserva. A descoberta de segmentos comportamentais numa fase inicial do processo pode apoiar estratégias de preços, planeamento de capacidade e comunicação direcionada, evitando simultaneamente a introdução de informação que apenas estaria disponível após a realização da reserva.

O estudo encontra-se estruturado em torno de cinco questões de investigação. A primeira (RQ1) procura determinar se emergem segmentos de reserva significativos na ausência de classificações pré-definidas. A segunda (RQ2) analisa de que forma diferentes representações dos dados influenciam a noção de semelhança entre observações. A terceira (RQ3) avalia qual a família de modelos oferece a melhor solução sob os critérios de seleção definidos. A quarta (RQ4) investiga se os clusters identificados são suficientemente interpretáveis para apoiar decisões. Finalmente, a quinta questão (RQ5) examina a sensibilidade dos resultados face à aleatoriedade inerente aos algoritmos e às escolhas de pré-processamento.

2. Dataset e Pré-processamento

2.1 Documentação do dataset

<i>Item</i>	<i>Valor reportado</i>
<i>Dataset e versão</i>	Hotel Booking Demand, <i>course release v1</i>
<i>Unidade de análise</i>	Uma linha = um registo de reserva
<i>Dimensão</i>	119 390 linhas × 32 colunas (bruto)
<i>Fonte e termos</i>	Pacote do <i>course release</i> (origem: António et al., 2019, fonte Kaggle)
<i>Checksum/hash</i>	SHA-256: 7c2ae42a7353905ea136e5c2287f17c92c5435826598bfb8491c6f0c7b1fc06
<i>Tratamento do bruto</i>	CSV bruto não committed; instruções de reprodução no README do repositório

2.2 Qualidade dos dados e governação de variáveis

A análise da qualidade dos dados encontra-se documentada nos ficheiros *tables/missingness_report.csv* e *tables/outlier_summary.csv*, onde são apresentados os resultados detalhados relativos a valores em falta e observações potencialmente extremas. Entre todas as variáveis analisadas, apenas a variável *children* apresentou valores em falta, correspondendo a quatro registos. Dada a reduzida dimensão deste problema e a plausibilidade operacional da ausência de crianças associada a um valor nulo, estes casos foram substituídos com o valor zero.

Relativamente à qualidade dos preços, foi aplicado um filtro específico sobre a variável ADR (*Average Daily Rate*), eliminando observações com valores inválidos ou claramente inconsistentes ($ADR \leq 0$ ou $ADR > 5000$). Esta operação resultou na exclusão de 1 961 registos.

O controlo de *data leakage* constituiu uma preocupação central do processo de preparação dos dados. Uma vez que o objetivo consiste em segmentar reservas com base apenas na informação disponível no momento da sua criação, foram excluídas variáveis que refletem resultados futuros ou informação posterior ao processo de reserva. Entre estas incluem *is_canceled*, *reservation_status* e *reservation_status_date*. Adicionalmente, foram removidos campos de identificação ou elevada cardinalidade (*agent*, *company* e *country*), bem como variáveis operacionais potencialmente influenciadas por eventos posteriores à reserva, nomeadamente *assigned_room_type*, *booking_changes* e *days_in_waiting_list*. Por fim, *arrival_date_year* foi excluído por redundância informacional face às restantes variáveis de calendário.

Para evitar a criação de demasiadas variáveis binárias frequentes, todos os níveis com frequência inferior a 1% foram agregados na categoria *Other* antes de aplicar o one-hot encoding. A representação principal do estudo, *Std-SemADR*, aplica *StandardScaler* às variáveis numéricas e codificação one-hot às categóricas (*handle_unknown="ignore"*). Obtém-se assim uma matriz com 52 dimensões, em que a distância entre reservas é medida pela distância euclidiana.

A tabela abaixo sintetiza as principais decisões de qualidade e governação que deram origem ao dataset analítico utilizado nas fases subsequentes do estudo.

<i>Passo de transformação</i>	<i>Justificação</i>	<i>Efeito</i>
<i>Substituir children em falta por 0</i>	Ausência de valor = zero crianças	4 linhas
<i>Remover ADR inválido ($0 < ADR \leq 5000$)</i>	Eliminar preços inválidos	1 961 linhas removidas
<i>Excluir variáveis de leakage/pós-evento</i>	Só informação disponível na reserva	10 colunas excluídas
<i>Agrupar categorias com <1% em Other</i>	Menos níveis raros no one-hot	Níveis raros → Other

<i>Codificar + escalar (Std-SemADR)</i>	Comparar variáveis em escala semelhante	Matriz de 52 dimensões
---	---	------------------------

Após o pré-processamento, a base analítica final contém 117 429 reservas. Todas as transformações estão implementadas em `edaClean.py` e `pipeline_utils.py`, o que permite reproduzir cada passo da preparação dos dados.

3. Métodos de Clustering

O método de referência adotado neste estudo é o K-Means, aplicado a um conjunto pré-definido de valores para o número de clusters $k \in \{3,4,5,6,7,8\}$, utilizando dez inicializações independentes (`n_init=10`) e uma *seed* (42) fixa durante o processo de seleção principal. Esta abordagem permite explorar diferentes números de segmentos, mantendo simultaneamente um protocolo experimental consistente.

Como alternativa, foi incluído o algoritmo iK-Means, capaz de determinar automaticamente o número de clusters a partir dos dados. Este método foi aplicado sobre as mesmas representações utilizadas pelo K-Means, recorrendo ao parâmetro `min_cluster_size=11`.

Foi ainda considerado clustering hierárquico aglomerativo (Ward). Dado o elevado custo computacional em grandes volumes de dados, aplicámo-lo apenas a uma subamostra fixa de 20 000 reservas (`seed=42`), na representação Std-SemADR e com $k=4$, permitindo comparar uma abordagem distinta da segmentação por centroides (K-Means).

As representações principal e de sensibilidade são:

<i>Representação</i>	<i>Escala das variáveis numéricas</i>	<i>ADR nas features</i>	<i>Tratamento do calendário</i>	<i>Dimensões</i>	<i>Linhas</i>
Std-SemADR	Standard	Não	Mês em OHE	52	117 429
Robust-SemADR	Robust	Não	Mês em OHE	52	117 429
Std-ComADR	Standard	Sim(+ remove outliers de ADR)	Mês em OHE	53	113 380
Std-SemADR+weekday	Standard	Não	Mês OHE + semana/dia numéricos	54	117 429

Para manter as comparações justas, todas as métricas internas são calculadas no mesmo espaço em que cada modelo é treinado. K-Means e iK-Means iniciação sobre o dataset completo em cada representação; Ward é avaliado num subconjunto fixo de 20 mil linhas (`sample_indices_20k_seed42.txt`) e complementado por um dendrograma (1500 pontos) que apenas serve para visualizar a estrutura hierárquica

A escolha de k na configuração principal segue o seguinte critério: maior silhouette entre os valores testados, desde que o cluster mais pequeno tenha pelo menos 1% das observações ($\text{min_cluster_pct} \geq 1\%$). Evitando assim escolher soluções com micro-clusters por melhorar ligeiramente os índices.

4. Protocolo Experimental

Todas as experiências foram executadas através de um único ponto, implementado em `runAll.py`, responsável por coordenar a pipeline completa do projeto. Em cada execução, os ficheiros gerados anteriormente são removidos, é criado um identificador único (`run_id`) e os diferentes módulos são executados numa sequência pré-definida, garantindo consistência e reprodutibilidade.

Os resultados de cada experiência são registados em `src/experiments.csv`, incluindo a informação relativa ao método utilizado, parâmetros de configuração, número de observações, métricas de avaliação, diagnósticos complementares, tempos de execução e observações relevantes.

O protocolo experimental assenta em cinco pilares fundamentais:

- **Pesquisa pré-definida:** utilização de um conjunto fixo de valores de k e configurações previamente especificadas para cada algoritmo.
- **Avaliação da estabilidade:** repetição das experiências com dez *seeds* distintas, recorrendo a métricas como o Adjusted Rand Index (ARI) e à comparação dos perfis obtidos;
- **Validade interna:** utilização conjunta dos índices Silhouette, Calinski–Harabasz e Davies–Bouldin para avaliar a qualidade das partições;
- **Restrições de governação:** imposição da condição $\text{min_cluster_pct} \geq 1\%$ para garantir a relevância operacional dos segmentos identificados;
- **Análises de sensibilidade:** estudo do impacto de diferentes escolhas de representação, escalonamento, inclusão de ADR e redução de dimensionalidade através de PCA.

A inclusão do método de Ward tem como objetivo complementar a análise com uma perspetiva hierárquica baseada na minimização da perspectiva hierárquica, permitindo comparar resultados obtidos com os métodos por centroides.

Blocos experimentais

<i>Bloco</i>	<i>Objectivo</i>	<i>Output principal</i>
Modelos de referência	Escolher o K-Means final ($k= 3$ a 8), com regra de cluster mínimo $\geq 1\%$	<code>k_sweep_summary.csv</code> , <code>selected_k.txt</code> , CSV de perfis
Família alternativa	Comparar algoritmos (K-Means, Ward e iK-Means) numa amostra de 20 000 reservas	Linhas de comparação 20k em <code>experiments.csv</code> , dendrograma
Testes de robustez	Ver se os resultados se mantêm ao mudar a seed ou a forma de representar os dados	<code>stability_report.csv</code> , CSVs de sensibilidade de perfis

Mapa de rastreabilidade reprodutível

<i>Artefacto</i>	<i>Papel na reprodutibilidade</i>
<i>environment.yml</i>	Especificação do ambiente
<i>runAll.py</i>	Corre toda a pipeline com um único comando
<i>src/pipeline_run.json</i>	Identificador e data da execução (<i>run_id</i>)
<i>src/experiments.csv</i>	Registo de todas as experiências e métricas
<i>src/k_sweep_summary.csv, src/selected_k.txt</i>	Documentam a escolha de <i>k</i>
<i>src/stability_report.csv</i>	Variabilidade entre <i>seeds</i> aleatórias
<i>src/cluster_profile_k4.csv</i>	Tabela de perfis final usada na interpretação
<i>src/graficos_relatorio/, tables/</i>	Figuras e tabelas de diagnóstico

5. Resultados e Interpretação dos Clusters

5.1 Resultados da preparação dos dados

Após as etapas de limpeza, validação e preparação das variáveis, o dataset analítico final passou a conter 117 429 observações e 22 variáveis, antes da transformação para o espaço de representação utilizado pelos algoritmos de clustering. Após a codificação e a normalização da representação principal (*Std-SemADR*), a matriz resultante passa a ter 52 dimensões.

As exclusões efetuadas decorreram principalmente da necessidade de evitar situações de *data leakage* e de garantir que apenas informação disponível no momento da reserva contribuísse para a construção dos clusters. A variável ADR foi excluída da configuração principal e analisada apenas em teste de sensibilidade controlados.

Comparativamente ao dataset original no *course release*, que continha 119 390 registos, a versão final mantém aproximadamente 98,36% das observações. Este resultado demonstra que a estratégia de limpeza utilizada conservou a maior parte dos dados, removendo apenas casos claramente problemáticos ou incompatíveis com os objetivos do estudo.

Importa ainda referir que a identificação de valores extremos foi usada sobretudo diagnosticar a qualidade dos dados. Com exceção do filtro aplicado ao ADR, onde não foram removidos outliers de forma sistemática, uma vez que tal remoção poderia eliminar padrões reais de comportamento e comprometer a representatividade da procura hoteleira.

5.2 Comparação de modelos

O objetivo principal da comparação entre modelos consistiu em identificar a solução que melhor equilibrasse qualidade da segmentação, consistência dos resultados e utilidade prática. Para isso, testamos diferentes famílias

de algoritmos e formas de representação dos dados, avaliadas através com métricas internas e critérios de seleção previamente definidos.

A tabela abaixo resume os resultados obtidos para as configurações selecionadas de cada método.

<i>Método</i>	<i>Configuração selecionada</i>	<i>Evidência de validade</i>	<i>Evidência de estabilidade</i>	<i>Observação principal</i>
K-Means	Std-SemADR, k=4	Sil 0,1256; CH 10 911,93; DB 2,0977; cluster mín. 2,93%	ARI 0,6675; concordância de perfis 0,8889	Melhor equilíbrio entre qualidade e tamanho dos segmentos
iK-Means	Std-SemADR, k automático = 12	Sil 0,1092; cluster mín. 0,76%	Não selecionado como partição final	Útil para explorar, mas não escolhido (cluster mínimo < 1%)
Ward (20k)	Std-SemADR, k = 4	Sil 0,2925, DB 1,6444, cluster mín. 0,15%	Só subamostra	Silhouette mais alta, mas cluster muito pequeno (0,15%)

Os resultados evidenciam que o K-Means na representação Std-SemADR com $k=4$ oferece o melhor equilíbrio entre qualidade da segmentação e tamanho mínimo dos clusters. Embora algumas soluções apresentem valores superiores em determinadas métricas individuais, estas tendem a gerar segmentos excessivamente reduzidos, limitando a sua utilidade prática.

A solução produzida pelo iK-Means revelou-se útil para exploração de dados, demonstrando a capacidade do algoritmo para identificar estruturas mais detalhadas. Contudo, a presença de clusters abaixo do limiar mínimo (1%) definido impediram escolha como solução final.


O método hierárquico (Ward) apresentou resultados favoráveis em termos de coesão e separação dos clusters na subamostra analisada. Ainda assim, a existência de micro-clusters e a necessidade de utilizar apenas sobre subconjuntos dos dados dificultam a sua utilização como abordagem principal para o problema em estudo.

A Tabela seguinte apresenta os resultados completos do teste realizado para o K-Means para $k=3$ a 8 na representação Std-SemADR.


<i>k</i>	<i>Silhouette</i>	<i>Davies–Bouldin</i>	<i>Cluster mín. (%)</i>	<i>Admissível</i>
3	0,1213	2,3581	2,83	Sim
4	0,1256	2,0977	2,93	Sim (selecionado)
5	0,0953	1,8804	0,76	Não
6	0,1140	1,6876	0,12	Não
7	0,1201	1,5764	0,18	Não
8	0,1413	1,4881	0,12	Não

Embora os índices de validade interna tendam a melhorar para valores mais elevados de k , verifica-se igualmente uma redução significativa da dimensão dos clusters mais pequenos. Demonstrando assim a importância do critério utilizado, acabando por evitar a escolha de soluções demasiado fragmentadas e difíceis de utilizar na prática num contexto real.


A pipeline experimental inicia de ponta a ponta pelo script *runAll.py*, produzindo gráficos e tabelas de diagnóstico, guardados de forma estruturada na pasta *src/graficos_relatorio/*. Estes resultados validam as decisões tomadas ao longo do pré-processamento e fundamentam a escolha da segmentação final.




A **Figura 1** mostra a distribuição do ADR (Average Daily Rate) antes e após o filtro de qualidade em *edaClean.py*. No painel esquerdo (*ADR original*), é possível verificar-se o forte impacto de preços inválidos (≤ 0 ou > 5000), que comprimem a escala do gráfico dificultando a leitura da distribuição. No painel direito (*ADR após clean de qualidade*) verifica-se que o filtro remove apenas preços inválidos, mantendo cerca de 98,36% das reservas, deixando visível a massa principal dos preços num intervalo coerente sem a eliminação de preços elevados ainda plausíveis.



A variabilidade das restantes variáveis numéricas que integram a matriz principal (Std-SemADR) encontra-se detalhada na **Figura 2**. Os boxplots mostram forte assimetria positiva, sobretudo em *lead_time* e *total_of_special_requests*. Este cenário justifica o uso do *StandardScaler* para colocar as variáveis da mesma escala antes das distâncias euclidianas. Adicionalmente, reforça a decisão de não remover outliers, preservando os padrões reais de reserva.




Complementarmente, a **Figura 3** apresenta histogramas com curva de densidade (KDE) para a antecedência da reserva (lead_time) e para o ADR. No *lead time* verifica-se que a esmagadora maioria das marcações ocorre num horizonte inferior a 100 dias de antecedência, embora persista um fluxo contínuo de planeamento a longo prazo que ultrapassa os 400 dias. Por sua vez no ADR, a distribuição é unimodal e estabilizada, com picos entre 80 e 100, confirmando a remoção de preços inválidos na limpeza.




Para introduzir uma abordagem hierárquica não baseada em centroides, a **Figura 4** apresenta o dendrograma Ward, calculado sobre uma subamostra de 1500 registos para garantir a viabilidade computacional da operação. A linha tracejada indica o nível de corte de $k=4$ clusters. A topologia da árvore evidencia a bifurcação de dois grandes ramos estruturais que, ao dividem-se numa separação em quatro grupos, coerente a solução de referente do K-Means.

Por fim, os resultados decorrentes da extensão E4 (Estudo PCA/SVD) encontram-se sintetizados nas **Figuras 5 e 6**.



A **Figura 5** compara o espaço original de 54 dimensões (Std-SemADR+weekday, usado apenas no E4) e o espaço reduzido de 18 componentes, testando $k=3$ a 8, num total de 5 seeds. Embora o painel esquerdo sugira uma aparente melhoria no índice Silhouette médio para o PCA, as barras de erro e o comportamento do índice Davies – Bouldin (painel direito) denunciam uma maior instabilidade entre execuções PCA. Reforça-se assim a decisão de não utilizar o PCA e de manter a representação principal Std-SemADR (52 dimensões) como solução final.



A **Figura 6** mostra a variância explicada por cada componente (painel esquerdo) e a variância acumulada (painel direito). Para reter no mínimo 90% da informação contida nas 54 dimensões do espaço original, foram selecionados 18 componentes principais.

5.3 Perfis dos clusters

A solução final selecionada identifica quatro segmentos distintos de reservas, cujas características permitem uma interpretação consistente do comportamento dos clientes.

<i>Cluster</i>	<i>Dimensão</i>	<i>Características principais</i>	<i>Interpretação</i>	<i>Nome do segmento</i>
C0	44 891 (38,23%)	Online TA, <i>lead time</i> 76, 4 noites	Reservas OTA muito antecipadas, estadias mais longas	Online long-stay
C1	62 366 (53,11%)	Online TA, <i>lead time</i> 78, 2 noites	Maior segmento OTA, estadias curtas	Online short-stay
C2	6 726 (5,73%)	Online TA, <i>lead time</i> 25, 3 noites	OTA com menor antecedência	Online near-term
C3	3 446 (2,93%)	Corporate, <i>lead time</i> 5, 2 noites	Reservas corporativas, baixa antecedência	Corporativo

Os clusters C0 e C1 concentram a maioria das reservas e partilham o perfil Online TA (canais online e TA/TO). Apesar disso, distinguem-se sobretudo pela duração típica da estadia: C0 com estadias mais longas (4 noites) e C1 com estadias mais curtas (2 noites).

O C2 apresenta antecedência claramente inferior (*lead time* $\approx$ 25 dias), podendo verificar reservas mais próximas da data de chegada. Mantém o perfil online dominante, mas com comportamento de reserva distinto.

O C3 destaca-se pelo segmento corporativo e baixa antecedência (*lead time* de 5 dias). Embora seja o menor segmento (2,93%), mostra um perfil claro e consistente, com relevância prática para a gestão hoteleira.

Importa salientar que esta interpretação é posterior ao clustering (post-hoc) não influenciando na criação dos grupos. As variáveis de resultados ou associadas a eventos posteriores à reserva permaneceram excluídas, preservando assim a validade da segmentação. Adicionalmente a diferenciação entre os clusters online não depende apenas das categorias modais (iguais em C0–C2), mas sobretudo de variáveis numéricas como a antecedência da reserva e duração da estadia. Esta observação reforça a importância de complementar a análise das categorias predominantes com medidas descritivas das variáveis numéricas.

5.4 Resumo de sensibilidade e extensão

Com o objetivo de avaliar a robustez das conclusões obtidas, foram conduzidas várias análises de sensibilidade incidindo sobre diferentes componentes da pipeline de pré-processamento e representação dos dados.

<i>Verificação</i>	<i>Resultado principal</i>	<i>Impacto na interpretação</i>
<i>Standard vs Robust</i>	Robust gera micro-clusters (ex: 0,12%)	Standard mantém-se como escalonador principal
<i>SemADR vs ComADR</i>	Alta concordância de perfis no subconjunto comum; ComADR remove 4 049 reservas (IQR ADR)	Incluir ADR altera mais a distribuição entre clusters do que a interpretação geral
<i>Enriquecimento calendário (+weekday)</i>	Silhouette em k=4 desce de 0,1256 para 0,0842	Semana/dia brutos pioram a segmentação; mês em one-hot preferido
<i>Extensão PCA (E4)</i>	Ver detalhes na subsecção E4 do relatório	Apenas diagnóstico; segmentação final no espaço original

De forma geral, os resultados indicam que a interpretação dos clusters mantém-se relativamente estáveis face a alterações moderadas na representação dos dados. Ainda assim, algumas escolhas metodológicas revelaram grande impacto na qualidade das partições.

A substituição do StandardScaler pelo RobustScaler originou micro-clusters em várias configurações, comprometendo o não cumprimento do critério de cluster mínimo $\geq 1\%$. Justificando assim o uso da padronização como opção principal.

A inclusão do ADR alterou parcialmente a distribuição das reservas pelos clusters, não mudando de forma relevante a interpretação geral dos perfis. Em contraste, a introdução de variáveis temporais adicionais relacionadas com o dia da semana e do mês revelou um efeito negativo nas métricas internas (Sil k=4: 0,1256 $\rightarrow$ 0,0842).

Extensão E4 — Estudo PCA/SVD

A extensão E4 teve como objetivo analisar o impacto da redução de dimensionalidade (PCA) na qualidade do clustering. O procedimento foi aplicado a um espaço de 54 dimensões, retendo 90% da variância acumulada.

O modelo manteve 18 componentes principais, reduzindo a dimensionalidade sem perder a maior parte da variância. Os resultados obtidos mostram melhorias moderadas em algumas métricas internas, nomeadamente o Silhouette ($k=4$: 0,0937 -> 0,1171). Contudo verificou-se maior variabilidade entre seeds e diferenças no k que maximiza o Silhouette, sugerindo assim que a retenção de variância não irá garantir a preservação das estruturas úteis para a segmentação.

Por isso, a solução acaba por se manter na representação Std-SemADR original, favorecendo a clareza na leitura dos resultados, a ligação direta entre clusters e comportamentos de reserva no domínio hoteleiro.

6. Discussão

Os resultados obtidos demonstram que é possível identificar segmentos de reserva distintos usando apenas informação disponível no momento da reserva. A solução K-Means com $k=4$ foi a alternativa mais equilibrada entre qualidade da segmentação, estabilidade e utilidade prática, respondendo de forma positiva às questões de investigação definidas no início do projeto.

As análises realizadas evidenciam que as decisões de pré-processamento influenciam de forma decisiva a estrutura final dos clusters. Alterações aparentemente simples, como a normalização das variáveis numéricas ou a inclusão de variáveis, podem alterar significativamente a distribuição das reservas e a estabilidade das partições.

Os perfis identificados apresentam uma interpretação coerente com a realidade do setor hoteleiro. A predominância de segmentos online confirma a importância na procura, enquanto o cluster corporativo (C3) sugere padrões específicos que podem justificar estratégias diferenciadas de gestão de comunicação.

Apesar destes resultados positivos, a estabilidade observada no ARI (0,6675) indica que alguns clusters mudam ligeiramente consoante a seed utilizada. Sendo que estes devem ser vistos como aproximações de padrões comportamentais, e não como categorias fixas.

Por fim, os resultados reforçam a importância de combinar métricas internas com critérios de seleção. A otimização isolada de indicadores como o Silhouette ou Davies-Bouldin levaria a soluções demasiado fragmentadas (ex: $k=8$), não sendo úteis na prática.

7. Limitações, Ética e Reprodutibilidade

O presente estudo apresenta várias limitações que devem ser consideradas na interpretação dos resultados. Em primeiro lugar, a ausência de classificações de referência impede a validação externa dos clusters.

Em segundo lugar, a distância euclidiana sobre variáveis one-hot pode não refletir relações semânticas entre categorias. Adicionalmente, o clustering hierárquico e os dendrogramas foram aplicados a subamostras fixas por limitações computacionais.

Do ponto de vista ético, os dados foram anonimizados, não sendo feitas inferências individuais nem decisões automatizadas com impacto sobre indivíduos.

Quanto à reprodutibilidade os procedimentos estão documentados nos repositórios. O ambiente está em *environment.yml*: a pipeline corre com o *runAll.py*. Tabelas, figuras e *experiments.csv* são gerados automaticamente, garantindo a transparências e rastreabilidade. Contudo o dataset bruto deve ser obtido separadamente (Ver Readme.md e o SHA-256).

8. Uso de IA

Durante a realização do trabalho, foi utilizada a inteligência artificial para o auxílio do relatório, e para brainstorming de ideias e formas de como devíamos implementar as propostas do enunciado.

9. Conclusão

Este trabalho abordou a segmentação de reservas hoteleiras com aprendizagem não supervisionada, num protocolo reprodutível sobre o dataset Hotel booking demand *course release v1*.

A análise realizada permitiu identificar quatro segmentos distintos de reservas através da solução K-Means com $k=4$, selecionando com base em métricas internas, critérios de seleção (cluster min $\geq 1\%$) e análise de estabilidade. Os perfis obtidos revelam diferenças relevantes ao nível do segmento de mercado, antecedência da reserva e duração da estadia.

Os testes de sensibilidade demonstraram que a interpretação global mantém-se consistente face a alterações na representação, embora alguns clusters variem consoante a *seed*.

Metodologicamente, o estudo demonstra a importância de combinar métricas quantitativas com critérios de utilidade prática. A simples otimização de índices internos revelou insuficiente para garantir segmentos úteis na prática.

Como trabalho futuro, seria interessante e relevante complementar a análise com estudos *post-hoc* que relacionem clusters com variáveis de resultados, como cancelamentos, mantendo sempre a separação entre fases de descoberta e validação para evitar *data leakage*

Em síntese, o projeto apresenta um fluxo experimental transparente e reprodutível, com decisões metodológicas, validação e interpretação alinhadas, tornando-o útil para a utilização em casos reais.

Referências

The pandas development team. (2024). pandas (Version 2.x) [Software]. <https://pandas.pydata.org>

Antônio, N., de Almeida, A., & Nunes, L. (2019). Hotel booking demand datasets. *Data in Brief*, 22, 41-49. <https://doi.org/10.1016/j.dib.2018.11.126>

Mostipak, J. (2019). *Hotel booking demand* [Dataset]
Kaggle. <https://www.kaggle.com/datasets/jessemmostipak/hotel-booking-demand>

Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.